Laboratorio Número 1 Aprendizaje Automático en Visión por Computadoras

Marco Moresi

11 de octubre de 2016

Índice

1. Introducción

En el presente informe se muestran los resultados del trabajo propuesto por la cátedra, el objetivo propuesto es familiarizarse con el **pipeline** de trabajo que habitualmente se utiliza en los proyectos de Aprendizaje Automático aplicado en Visión por Computadoras. A continuación se enumeran las consignas, luego para cada consigna se describe el trabajo realizado junto con los resultados y gráficos pertinentes.

2. Consignas

[0] Familiarizarse con el código y con el dataset.

[1] Determinar el mejor valor para el parámetro C del clasificador (SVM lineal) mediante 5-fold cross-validation en el conjunto de entrenamiento (gráfica) de uno de los folds. Una vez elegido el parámetro, reportar media y desviación estándar del accuracy sobre el conjunto de test.

[2] Evaluar accuracy vs. n_clusters. Que pasa con los tiempos de cómputo de BoVW?. Gráficas.

Si tengo descriptores locales L2-normalizados: cómo puedo optimizar la asignación de los mismos a palabras del diccionario? (ayuda: expresar la distancia euclídea entre dos vectores en términos de productos puntos entre los mismo)

[3] Transformaciones en descriptores / vectores BoVW: evaluar impacto de transformación sqrt y norma L2.

[4] Kernels no lineales: Intersección (BoVW: norm=1) y RBF, ajustando parámetros mediante cross-validation en conjunto de validación.

3. Ejercicios

3.1. Ejercicio 1

Como base se utilizó el archivo lab.py, para realizar **5-fold cross-validation**, se dividió el set de entrenamiento en 5 partes iguales, se tomaron las 4 primeras partes como **train_set** y última partición como **validation_set** se entrenaba y validaba el clasificador lineal (SVM Lineal) para cada valor C y se guardaba la medida de **accuracy** obtenida para cada valor de C en su respectiva lista. Luego concatenaba la partición correspondiente al **validation_set** al inicio del **train_set** y volvia a tomar las 5 particiones, del mismo modo que se menciona mas arriba, de esta forma tanto el **validation_set** como el **train_set** variaban en cada iteración.

Para llevar a cabo esta tarea se considero como primera instancia la siguiente lista de posibles valores:

$$list\_C = [10^{-3}, 10^{-2}, 10^{-1}, 10^{0}, 10^{1}, 10^{2}, 10^{3}]$$

Luego de la ejecución arrojó los siguientes valores:

$$10^{-3} = \begin{bmatrix} 0{,}37 & 0{,}36 & 0{,}366 & 0{,}416 & 0{,}386 \end{bmatrix}$$

$$10^{-2} = \begin{bmatrix} 0{,}453 & 0{,}46 & 0{,}463 & 0{,}506 & 0{,}49 \end{bmatrix}$$

$$10^{-1} = \begin{bmatrix} 0{,}546 & 0{,}596 & 0{,}563 & 0{,}616 & 0{,}596 \end{bmatrix}$$

$$10^{0} = \begin{bmatrix} 0{,}603 & 0{,}636 & 0{,}623 & 0{,}64 & 0{,}64 \end{bmatrix}$$

$$10^{1} = \begin{bmatrix} 0{,}613 & 0{,}646 & 0{,}61 & 0{,}633 & 0{,}633 \end{bmatrix}$$

$$10^{2} = \begin{bmatrix} 0{,}596 & 0{,}573 & 0{,}573 & 0{,}596 & 0{,}603 \end{bmatrix}$$

$$10^{3} = \begin{bmatrix} 0{,}503 & 0{,}493 & 0{,}526 & 0{,}553 & 0{,}52 \end{bmatrix}$$

Luego de tomar la media a cada lista obtenemos el siguiente resultado:

$$list\_median = \begin{bmatrix} 0{,}37 & 0{,}463 & 0{,}596 & 0{,}636 & 0{,}633 & 0{,}596 & 0{,}520 \end{bmatrix}$$

Anotacion: Los índices de list_median coinciden con los de list_C
e.g $C = 10^{-3}$ *media* $= 0{,}37$

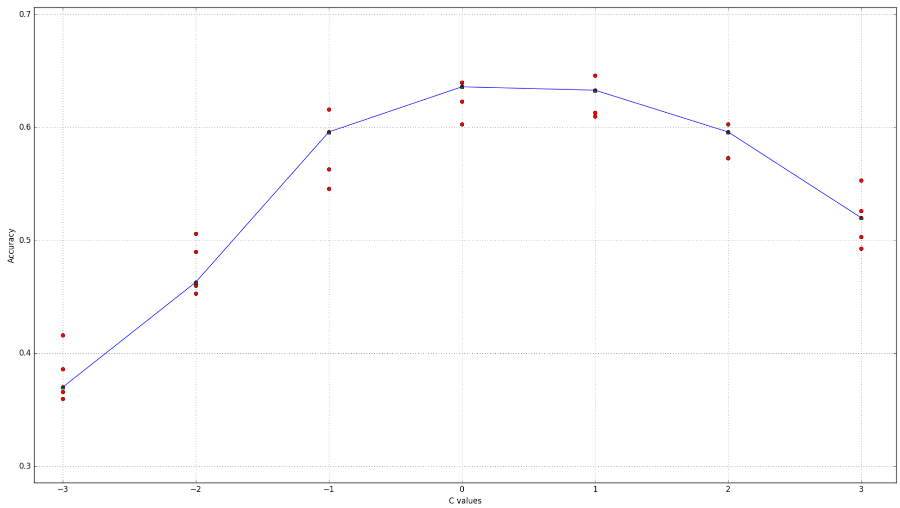

En la lista de medias, podemos ver que obtenemos mayores medias usando el parámetro C entre $[10^0, 10^1, 10^2]$

Por lo tanto, refiné el parámetro entre esos valores. Para ello volví a realizar **5-fold cross-validation** pero esta vez con:

Anotación: Para no aumentar mucho la extensión del informe sólo muestro las medias obtenidas para cada valor de C, en estos pasos intermedios. Acá podrá encontrar los valores completos.

$$list\_C = [1, 3, 5, 7, 9, 10]$$

$$list\_median = [0{,}646 \quad 0{,}633 \quad 0{,}636 \quad 0{,}636 \quad 0{,}626 \quad 0{,}626]$$

Ahora refino entre 0,1 y 2

$$list\_C = [0{,}1, 1, 2]$$

$$list\_median = [0{,}573 \quad 0{,}653 \quad 0{,}646]$$

Refino entre 0.5 y 2

$$list\_C = [0{,}5, 1, 1{,}5, 2]$$

$$list\_median = [0{,}650 \quad 0{,}660 \quad 0{,}670 \quad 0{,}663]$$

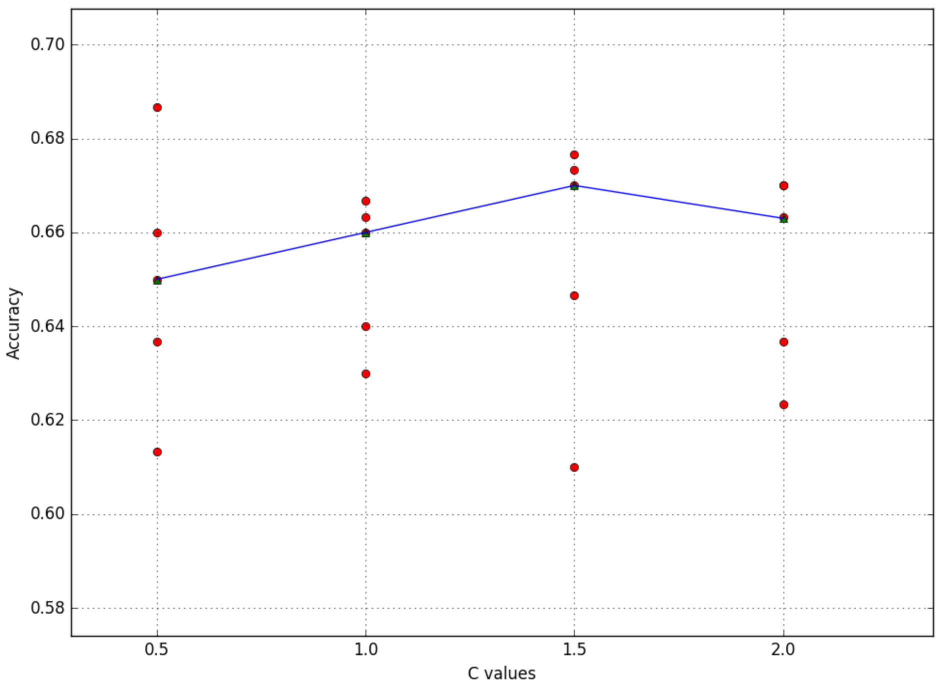

Como obtuve la media mas grande en 1.5, ese será a partir de ahora mi parámetro C, para el clasificador lineal. **C=1.5**

Ahora voy a medir la media y la varianza que obtengo con el parámetro C escogido. Para ello voy a ejecutar el pipeline 200 veces, variando el train_set y el test_set, tomando la medida de accuracy para cada corrida.

Desviación standard = 0.0067 accuracy = 0.6538

3.2. Ejercicio 2

Accuracy Vs. N_Clusters Por defecto en lab.py se utilizaban 100 clusters para ejecutar k-means. Lo que hice en este ejercicio fue probar distintos tamaños de clusters para el algoritmo K-means, medir cuanto tiempo demoraba en calcular los Bags of Visual Words y que accuracy obtenia el modelo con esa cantidad de clusters. Para ello definí una lista de posibles cantidad de clusters

$$clusters\_size = [1, 5, 10, 25, 50, 75, 100, 110, 125, 140, 150, 175, 200, 250, 300, 325]$$

Luego para medir el tiempo de demora en computar los BOVW utilice la libreria de python llamada time. Entonces antes de computar los BOVW tomo el tiempo con time.time() y cuando termina de computarlos tomo nuevamente el tiempo y la resta de ellos, me da una aproximación al tiempo que demora en calcularlos. Despues de calcularlos, tomarle el tiempo elimino los BoVW y comienzo de nuevo.

Los resultados obtenidos fueron los siguientes:

N_Clusters	Accuracy	Elapsed Time (Seg)
1	0.0472	4.4957
5	0.4177	6.3762
10	0.4606	8.1321
25	0.5504	13.7002
50	0.6100	22.8868
75	0.6428	30.9782
100	0.6566	40.1747
110	0.6753	42.3768
125	0.6646	48.1458
140	0.659	54.9081
150	0.683	57.8346
175	0.682	66.0863
200	0.683	75.4143
250	0.679	92.0769
300	0.663	109.572
325	0.661	118.4008

En el primer gráfico podemos ver el nivel de Accuracy en función de la cantidad de clusters, se observa que en N_Clusters = 150 y N_Clusters = 200 se alcanza el valor máximo de accuracy = 0.683. Entre 150 y 200 clusters tenemos una meseta en la función y luego de esto decae la performance.

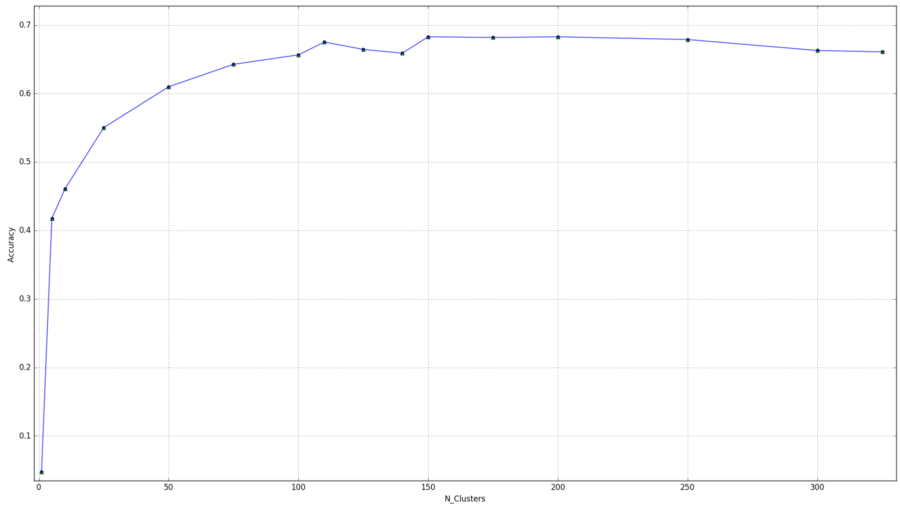

Veamos ahora cuanto demora en calcular los BOVW, si nos centramos donde alcanza la mayor accuracy vemos que en N_Clusters = 150 demora 57.8346 segundos aproximadamente mientras que en N_Clusters = 200 demora 75.4143 aproximadamente.

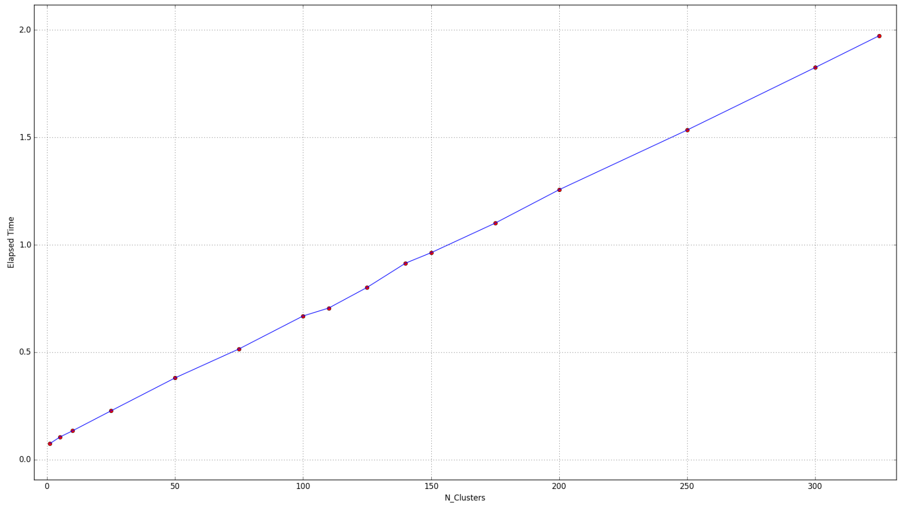

Ahora si podemos ambas funciones en el mismo gráfico, podemos ver como a medida que mas clusters usamos mayor es el tiempo que demanda para computar los BOVW, pero no necesariamente obtenemos mayor accuracy.

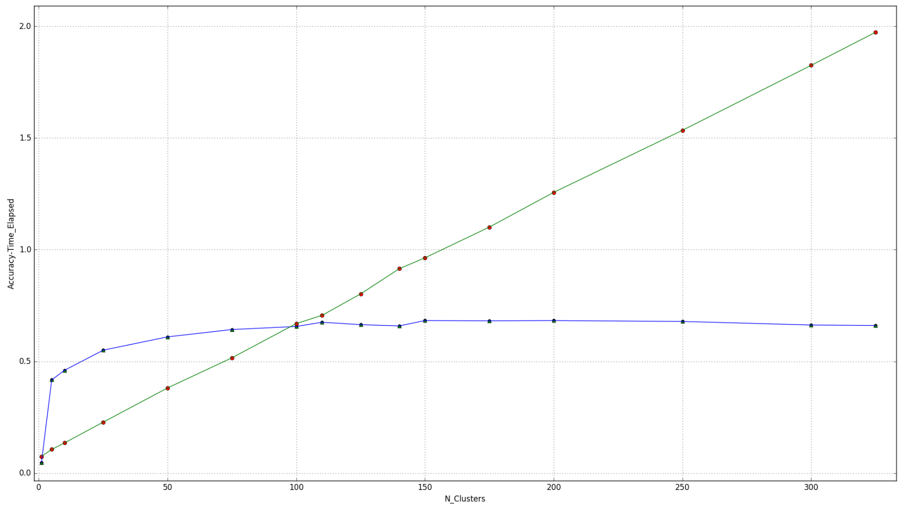

Anotación: El tiempo está expresado en minutos para que sea más fácil la visualización y sea evidente lo que menciono mas abajo

Teniendo en cuenta el Trade Off entre tiempo de cálculo y accuracy la mejor elección en este caso es usar N_Clusters = 150, que es el punto donde la función de la accuracy alcanza su máximo y esta lo más cerca posible de la función del tiempo.
De ahora en adelante considero **n_clusters = 150**

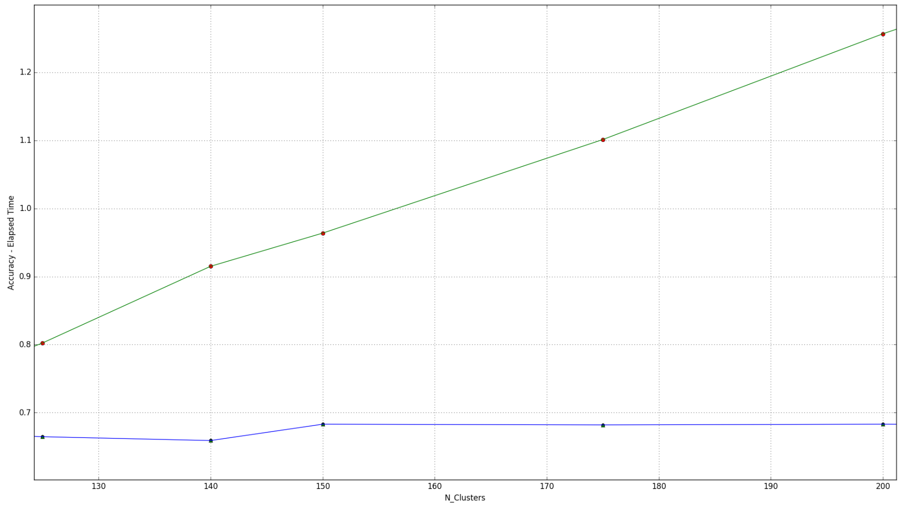

¿Cómo puedo optimizar la asignación de los mismos a palabras del diccionario?

Para optimizar la asignación lo que podría hacer es computar la distancia Euclidea como producto punto de vectores, esto es computacionalmente más rapido ya que los microprocesadores traen instrucciones que resuelven los productos puntos en muy poco tiempo. Vamos a escribir la distancia Euclidea entre dos vectores a y b como producto punto de ellos.

Primero defino (1): $||x||^2 = x^T x = \sum_{i=1}^{n}(x_i x_i)$

Veamos ahora la distancia Euclidea (L2)

$$||a-b||_2^2 = \sum_{i=1}^{n}(a_i - b_i)^2 = (a-b)^T(a-b) = a^T a - 2a^T b - b^T b$$

Aplicamos (1), obtenemos

$$= ||a||^2 - 2a^T b - ||b||^2$$

Entonces

$$||a-b||_2^2 = 2(1 - a^T b)$$

De este modo tenemos escrito la distancia L2 en forma de producto punto.

3.3. Ejercicio 3

En este ejercicio se pedia evaluar el impacto de transformaciones sqrt y norma L2, tanto en el calculo de features como en el de BOVW. Para usar transformaciones SQRT+L2, por consejo de la catedra, se decidió normalizar primero con norma l1 y luego tomarle raiz cuadrada a cada elemento del feature o bovw segun correspondiese. De este modo tenemos nueve combinaciones posibles para el calculo de features y BOVW:

$$\{(L2, L2), (SQRT, L2), (SQRT{+}L2, L2), (SQRT, L2), (SQRT, SQRT), (SQRT, SQRT{+}L2),$$

$$(SQRT + L2, L2), (SQRT + L2, SQRT), (SQRT + L2, SQRT + L2)\}$$

Para cada posible combinación primero se realizó 5-fold cross validation, para estimar el mejor valor de C para el clasificador SVM lineal, luego con el C que mayor media obtuve ejecuté el pipeline 200 veces, tomando la medida de accuracy en cada ejecución. Los resultados se pueden ver acá. Luego para cada combinación de normas tomé la media (μ) y varianza (σ)

Valores de C

BoVW / Daisy	**L2**	**SQRT**	**SQRT+L2**
L2	C = 1.5	C = 1.0	C = 1.0
SQRT	C = 0.001	C = 0.001	C = 0.001
SQRT+L2	C = 0.1	C = 1.0	C = 1.5

Media y Varianza Obtenida

BoVW / Daisy	**L2**	**SQRT**	**SQRT+L2**
L2	$\mu = 0{,}6740$ $\sigma = 0{,}0067$	$\mu = 0{,}6312$ $\sigma = 0{,}0065$	$\mu = 0{,}6789$ $\sigma = 0{,}0066$
SQRT	$\mu = 0{,}6908$ $\sigma = 0{,}0063$	$\mu = 0{,}6318$ $\sigma = 0{,}0067$	$\mu = 0{,}6879$ $\sigma = 0{,}0064$
SQRT+L2	$\mu = 0{,}6961$ $\sigma = 0{,}0051$	$\mu = 0{,}6385$ $\sigma = 0{,}0067$	$\mu = 0{,}7013$ $\sigma = 0{,}0067$

En la tabla podemos ver que utilizando SQRT+L2 para los descriptores Daisy y SQRT+LV para los BOVW obtenemos la mayor media. De ahora en más estas normalizaciones serán utilizadas en el pipeline.

3.4. Ejercicio 4

En este ejercicio se pedía utilizar un Kernel no lineal, utilizando RBF (Radial basis function kernel), mediante 5-Fold Cross-Validation vamos a ajustar dos parámetros de este clasificador C y Gamma. Utilicé el clasificador SVC que provee sklearn. Se emularon los pasos propuestos en este paper [2]. Para ello definí una lista de posibles Gammas y C

$$list\_C = [2^{-5}, 2^{-3}, 2^{-1}, 2^{1}, 2^{3}, 2^{5}, 2^{7}, 2^{9}, 2^{11}, 2^{13}, 2^{15}]$$

$$list\_gamma = [2^{-15}, 2^{-11}, 2^{-9}, 2^{-7}, 2^{-5}, 2^{-3}, 2^{-1}, 2^{1}, 2^{3}]$$

Los resultados completos pueden verlos acá. Los mejores medias fueron obtenidas con las siguientes combinaciones de parámetros.

C	γ	**lista de medias**	M	Varianza
32	2	[0.646, 0.71, 0.713, 0.716, 0.676]	$\mu = 0.710$	$\sigma = 0.02711$
2	2	[0.66, 0.71, 0.73, 0.72, 0.683]	$\mu = 0.710$	$\sigma = 0.02560$

Con la combinación C=2 y $\sigma = 2$ obtenemos la mayor media y con menor varianza.

Del mismo modo que para el kernel RBF, se evaluó la performance utilizando el Kernel de Intersección, visto en el teórico.

Los resultados obtenidos fueron

C	γ	**lista de medias**	M	Varianza
0.125	0.5	[0.64, 0.716, 0.72, 0.75, 0.696]	$\mu = 0.71667$	$\sigma = 0.03655$
0.125	2	[0.64, 0.716, 0.72, 0.75, 0.696]	$\mu = 0.71667$	$\sigma = 0.03655$

Luego de haber ajustado los parámetros para el kernel intersección ejecuté el pipeline 10 veces por cada uno de los pares C y Gamma que obtuve.

Los resultados obtenidos fueron, para C = 0.125 y $\gamma = 2$
Accuracy = 0.7035 y Desviación standard = 0.0063

Para C = 0.125 y $\gamma = 0.5$
Accuracy = 0.6990 y Desviacion standard = 0.0063

Por lo tanto los párametros que mejor se ajustan a este dataset para usar el kernel intersección son C = 0.125 y $\gamma = 2$

4. Conclusión

Para este pipeline de trabajo, sobre este dataset, usando un clasificador Lineal el mejor C que obtuve fue igual a 1.5, con una cantidad de 150 Clusters para el algoritmo de k-means. Más aún normalizando los features y BoVW con norma SQRT+L2 obtengo la mayor media $\mu = 0.7013$ y con $\sigma = 0.0067$.
En el caso de utilizar un clasificador no lineal con kernel RBF, obtuve la mayor media $\mu = 0.710$ y menor varianza $\sigma = 0.02560$, con parámetros C=2 y γ=2.

5. Bibliografía

Svetlana Lazebnik, Cordelia Schmid, and Jean Ponce. (2006) Beyond Bags of Features: Spatial Pyramid Matching for Recognizing Natural Scene Categories. In: CVPR. [1]

Hsu, C. W., Chang, C. C., & Lin, C. J. (2003). A practical guide to support vector classification.[2]

Arandjelović, R., & Zisserman, A. (2012). Three things everyone should know to improve object retrieval. In: CVPR. [3]

6. Referencias

[1] `http://www-cvr.ai.uiuc.edu/ponce_grp/data/scene_categories/scene_categories.zip`

[2] `http://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf`

[3]`https://www.robots.ox.ac.uk/~vgg/publications/2012/Arandjelovic12/arandjelovic12.pdf`